Contribution ModBlock GDR

#Data on agricultural output of GDR)

```
#======
# LPGs
#=======
# Objective: Build cross-section of LPG development in 1953 from digitized files
# Authors: Pana & Moritz

# Main tasks:
# Harmonize variable names
# Add names of Kreise when missing
# Bring all Bezirke together into one spreadsheet
# Alle Variablen zu doubles, ausser den Kreisnamen (die sind character)

# Delete all objects in your console
rm(list = ls())

# 2do: Suhl bind_cols to left_joins

# Load libraries
require(tidyverse) # Super Funktionen Sammlung
require(sf) # Fuer Karten und Geodaten
require(readxl) # Um Excel zu lesen
require(janitor) # Um Daten zu saeubern
require(glue)
require(broom) # Um regressionsoutput in datenform zu bringen

# Shapefile mit dt. Landkreisen 1953
#-----------------------------------------
# Laden mit dem sf package
ddr_brd <- read_sf("data/shapefile_1953/Germany_1953_v.1.0.shp")
# Clean names with function from janitor package
ddr_brd <- clean_names(ddr_brd)
# Visualisieren von BRD und DDR in 1953, Faerbung ist Groesse des
Kreisesplot(ddr_brd[,"area"])
# In Deutschland hat jede Gemeinde einen Code mit 8 Stellen (Wiki: Allgemeiner
Gemeindeschluessel, kurz AGS)
# Die ersten 5 Stellen sind fuer die Kreise, die ersten 2 fuer Bundeslaender
# Berlin ist 11, die andern Oestlichen Bundeslaender haben 12 bis 16
# Kodiere Variable mit Bundesland Schluesseln
ddr_brd <- ddr_brd %>%  mutate(bula_kenn = substr(kreis_kenn, 0,2))
# Nur die DDR
ddr <- ddr_brd %>% filter(bula_kenn %in% c(11:16))
plot(ddr[,"bula_kenn"])

# In der DDR wurde allerdings in anderes Schluesselsystem benutzt. Es gab auch die
Bundeslaender nicht mehr.
```

```
# Das System kommt aus der BRD und wurde in diesem Shapefile vom Max Planck Inst.
rueckwaertsgewandt auf die DDR uebertragen.

# Speichern aller Kreisnamen in einem data frame
glimpse(ddr)
kreise <- ddr %>% st_set_geometry(NULL) %>% select(bula_kenn, gen) %>%
arrange(bula_kenn)

# Das sind alle Kreise in der DDR in 1953
kreise %>% print(n=300)
# Koenntest Du die Kreisnamen weiter unten damit harmonisieren? Wird gemacht!

# Mit dieser Funktion kannst Du einen beliebigen Kreis auswaehlen und visualisieren
visualize_kreis = function(kreis) {
  ddr %>%
    mutate(label = ifelse(gen == kreis, gen, NA_character_)) %>%
    ggplot(aes(label = label, color = bula_kenn)) + geom_sf() + geom_sf_label() +
theme_void()
}
visualize_kreis("Jüterbog")


# SPREADSHEETS
#-----------------
# Load all files in the directory
file_names <- list.files(path = "./data/1953-06-30/spreadsheets/", full.names = T)
file_names

file_lpgs <- list.files(path = "./data/1953-06-30/fehlende_typen/spreadsheets",
                        pattern = "csv", full.names = T)
# Nur die files in denen uebernommen steht im Namen und die csv sind
file_lpgs <- file_lpgs[grepl("bernommen", file_lpgs)]

#Um LPGs einzufügen
library(readr)
library(dplyr)

# VARIABLE NAMES
#------------------
var_names <- c("kreis", "mitglieder_insg", "landarbeiter", "landarbeiter_fam",
               "neubauern", "neubauern_fam", "altbauern", "altbauern_fam", "sonst_berufe",
               "frauen_insg", "betriebe_insg", "betriebe_2ha", "betriebe_5ha", "betriebe_10ha",
               "betriebe_15ha", "betriebe_20ha", "betriebe_groesser20ha", "gen_flaechen_insg",
               "gen_flaechen_acker", "gen_flaechen_wiesen", "gen_flaechen_weiden",
               "gen_flaechen_forsten", "ges_betreu_technisch", "ges_betreu_agronomisch",
               "ges_betreu_tieraerztlich",  "gen_vieh_pferde", "gen_vieh_rinder_insg",
               "gen_vieh_rinder_kuehe", "gen_vieh_rinder_zugtiere", "gen_vieh_schweine",
"gen_vieh_schafe",
               "ind_flaechen_insg", "ind_flaechen_acker", "ind_flaechen_weiden",
"ind_flaechen_forsten", "ind_vieh_pferde",
```

```
            "ind_vieh_rinder_insg", "ind_vieh_rinder_zugtiere", "ind_vieh_schweine",
"ind_vieh_schafe")

#---------
# HALLE
#---------
# vollständig
read_excel(file_names[1])
halle <- read_excel(file_names[1], skip = 4)

#Kommentar Pana: ehemaliges LPGs alle hier rausgenommen, alles zusammen kommt
unten
# Auswahl relevanten Spalten
halle <- halle[,c(1,3:19,21,23,25,27,29:38,40,42,44,46:50)]

#Namen der Spalten anpassen
names(halle) <- var_names

# Korrektur der Kreisnamen
halle <- halle %>%
     mutate(kreis = case_when(
          kreis == "Grafenhausen" ~ "Gräfenhainichen",
          kreis == "Saalekreis" ~ "Saalkreis",
          kreis == "Oned Limburg" ~ "Quedlinburg",
          kreis == "Orierfurt" ~ "Querfurt",
          kreis == "Rosslan" ~ "Roßlau",
          kreis == "Weissenfels" ~ "Weißenfels",
          kreis == "Reiff" ~ "Zeitz",
          kreis == "Dessau (Stadt)" ~ "Dessau",
          kreis == "Halle (Stadt)" ~ "Halle/Saale",
          TRUE ~ as.character(kreis)
          ))
halle <- halle %>% mutate(across(where(is.character), ~na_if(., "-")))
halle <- halle  %>% type_convert()
halle$bezirk <- "Halle"

#Nachträglich einfügen der fehlenden LPGs
#Einlesen der Daten
file_lpgs[4]
halle_typen <- read_delim(file_lpgs[4], col_types = cols(
  kreis = col_character(),
  bezirk = col_character(),
  lpg_typ_alle = col_double(),
  lpg_typ_1 = col_double(),
  lpg_typ_2 = col_double(),
  lpg_typ_3 = col_double(),
  datum = col_character()  # Erst als Charakter einlesen
  )) %>%
  mutate(datum = as.Date(datum, format = "%d.%m.%y")) %>%
  mutate(kreis = ifelse(kreis == "Rosslau", "Roßlau", kreis))
```

```
anti_join(halle, halle_typen)
anti_join(halle_typen, halle)

halle <- inner_join(halle, halle_typen)

# Koenntest Du fuer diese zwei Variablen checken ob die Werte richtig sind?
halle$ind_flaechen_insg[1:2] == c(461, 533)
halle$gen_flaechen_insg[1:2] == c(5065, 10615)
# Pana: sind richtig!

# Das hier wird unser data frame in dem wir alles sammeln
lpgs <- halle
glimpse(lpgs)

#---------
# Potsdam
#---------
# vollständig
read_excel(file_names[2])
potsdam <- read_excel(file_names[2],  skip = 4)

# Die Anzahl der LPG Typen ziehen wir raus und kleben die spaeter wieder dran
potsdam_typen <- potsdam[,c(2:5)]

# Umbenennen
names(potsdam_typen) <- c("lpg_typ_alle", "lpg_typ_1", "lpg_typ_2", "lpg_typ_3")

# Ersetze in allen Variablen - durch NA
potsdam_typen <- potsdam_typen  %>% mutate(across(where(is.character), ~na_if(., "-")))
potsdam_typen <- potsdam_typen  %>% type_convert()

# Die restlichen Variablen
potsdam <- potsdam[,c(1,6:22,24,26,28,30,32:41,43,45,47,49:53)]
potsdam <- potsdam %>% set_names(var_names)
potsdam <- potsdam %>%
  mutate(kreis = case_when(
   kreis == 1 ~ "Belzig",
   kreis == 2 ~ "Brandenburg-Land",
   kreis == 3 ~ "Gransee",
   kreis == 4 ~ "Jüterbog",
   kreis == 5 ~ "Königs-Wusterhausen",
   kreis == 6 ~ "Kyritz",
   kreis == 7 ~ "Luckenwalde",
   kreis == 8 ~ "Nauen",
   kreis == 9 ~ "Neuruppin",
   kreis == 10 ~ "Potsdam-Land",
   kreis == 11 ~ "Pritzwalk",
   kreis == 12 ~ "Oranienburg",
   kreis == 13 ~ "Rathenow",
```

```
    kreis == 14 ~ "Wittstock",
    kreis == 15 ~ "Zossen",
    kreis == 16 ~ "Brandenburg/Havel",
    kreis == 17 ~ "Bezirk Potsdam insges",
    TRUE ~ as.character(kreis)
    ))
potsdam <- potsdam %>% mutate(across(where(is.character), ~na_if(., "-")))
potsdam <- type_convert(potsdam)
potsdam <- potsdam %>%  mutate(bezirk = "Potsdam")

# Die LPG Typen ankleben an den Rest, der Reihenfolge nach
potsdam <- bind_cols(potsdam, potsdam_typen)

# Am Ende kleben wir das vertikal auf einander mit den Daten aus Halle.
# Da die Variablen "lpg_typ_1", "lpg_typ_2", "lpg_typ_3" noch nicht in Halle sind bleibt das
erstmal NA.
lpgs <- bind_rows(lpgs, potsdam)

#---------
# Rostock
#---------
# vollständig
read_excel(file_names[3])
rostock <- read_excel(file_names[3], skip = 4)

# Anzahl der LPG Typen
rostock_typen <- rostock[,c(2:5)]
# Ersetze in allen Variablen - durch NA
rostock_typen <- rostock_typen  %>% mutate(across(where(is.character), ~na_if(., "-")))
rostock_typen <- rostock_typen  %>% type_convert()

# Vorsicht!!! Hier ist die Reihenfolge anders als in Potsdam.
names(rostock_typen) <- c("lpg_typ_1", "lpg_typ_2", "lpg_typ_3", "lpg_typ_alle")

# Die restlichen Variablen
rostock <- rostock[,c(1,6:22,24,26,28,30,32:41,43,45,47,49:53)]
names(rostock) <- var_names
rostock <- rostock %>%
   mutate(kreis = case_when(
    kreis == 1 ~ "Bad Doberan",
    kreis == 2 ~ "Bergen",
    kreis == 3 ~ "Ribnitz-Damgarten",
    kreis == 4 ~ "Putbus",
    kreis == 5 ~ "Greifswald",
    kreis == 6 ~ "Grevesmühlen",
    kreis == 7 ~ "Grimmen",
    kreis == 8 ~ "Rostock-Land",
    kreis == 9 ~ "Stralsund-Land",
    kreis == 10 ~ "Wismar-Land",
    kreis == 11 ~ "Wolgast",
```

```
    kreis == 12 ~ "Rostock",
    kreis == 13 ~ "Bezirk Rostock insges",
    TRUE ~ as.character(kreis)
    ))
rostock <- rostock %>% mutate(across(where(is.character), ~na_if(., "-")))
rostock <- type_convert(rostock)
rostock <- rostock %>%  mutate(bezirk = "Rostock")

# Mit den anderen Variablen zusammen binden
rostock <- bind_cols(rostock, rostock_typen)
lpgs <- bind_rows(lpgs, rostock)

# Dates
lpgs <- lpgs %>% mutate(datum = dmy(datum))

#---------------
#Neubrandenburg
#----------------
# vollständig
file_names[4]
read_excel(file_names[4])
neubrandenburg <- read_excel(file_names[4], skip = 4)

#Anmerkung Pana: auch hier habe ich alles rausgenommen, der Code von unten reicht
tatsächlich
neubrandenburg <- neubrandenburg[c(1:15),c(1,3:19,21,23,25,27,29:38,40,42,44,46:50)]
#nur die ersten 15 Zeilen benutzt; Typ 1 ignoriert
names(neubrandenburg) <- var_names
neubrandenburg <- neubrandenburg %>%  mutate(bezirk = "Neubrandenburg")
neubrandenburg$sonst_berufe <- as.double(neubrandenburg$sonst_berufe)
neubrandenburg <- neubrandenburg %>%
  mutate(kreis = case_when(
    kreis == "Röbel" ~ "Röbel/Müritz",
    kreis == "Insgesamt" ~ "Bezirk Neubrandenburg insges",
    TRUE ~ as.character(kreis)
    ))

#Nachträglich einfügen der fehlenden LPGs
#Einlesen der Daten
neubrandenburg_typen <- read_delim(file_lpgs[7], col_types = cols(
  kreis = col_character(),
  bezirk = col_character(),
  lpg_typ_alle = col_double(),
  lpg_typ_1 = col_double(),
  lpg_typ_2 = col_double(),
  lpg_typ_3 = col_double(),
  datum = col_character()  # Erst als Charakter einlesen
)) %>%
  mutate(datum = as.Date(datum, format = "%d.%m.%y"))
```

```
# Check mismatch
anti_join(neubrandenburg, neubrandenburg_typen)
neubrandenburg <- left_join(neubrandenburg, neubrandenburg_typen)

lpgs <- bind_rows(lpgs, neubrandenburg)

#---------------
# Schwerin
#---------------
# vollständig
file_names[5]
read_excel(file_names[5])
schwerin <- read_excel(file_names[5], skip = 4)
schwerin <- schwerin[c(1:12),c(1:18,20,22,24,26,28:37,39,41,43,45:49)]
names(schwerin) <- var_names
schwerin <- schwerin %>%
   mutate(kreis = case_when(
    kreis == 1 ~ "Bützow",
    kreis == 2 ~ "Gadebusch",
    kreis == 3 ~ "Güstrow",
    kreis == 4 ~ "Hagenow",
    kreis == 5 ~ "Ludwigslust",
    kreis == 6 ~ "Lübz",
    kreis == 7 ~ "Parchim",
    kreis == 8 ~ "Perleberg",
    kreis == 9 ~ "Schwerin-Land",
    kreis == 10 ~ "Sternberg",
    kreis == 11 ~ "Schwerin",
    kreis == 12 ~ "Bezirk Schwerin insges",
    TRUE ~ as.character(kreis)
    ))
schwerin <- schwerin %>% mutate(across(where(is.character), ~na_if(., "-")))
schwerin <- type_convert(schwerin)
schwerin <- schwerin %>%  mutate(bezirk = "Schwerin")

#Nachträglich einfügen der fehlenden LPGs
#Einlesen der Daten
schwerin_typen <- read_delim(file_lpgs[8], col_types = cols(
  kreis = col_character(),
  bezirk = col_character(),
  lpg_typ_alle = col_double(),
  lpg_typ_1 = col_double(),
  lpg_typ_2 = col_double(),
  lpg_typ_3 = col_double(),
  datum = col_character()  # Erst als Charakter einlesen
)) %>%
#Datum nachträglich als solches umformatieren (geht nicht anders)
  mutate(datum = as.Date(datum, format = "%d.%m.%y"))
```

```
anti_join(schwerin, schwerin_typen)
anti_join(schwerin_typen, schwerin)
schwerin <- inner_join(schwerin_typen, schwerin)

lpgs <- bind_rows(lpgs, schwerin)

#---------------
# Magdeburg
#---------------
# vollständig
read_excel(file_names[6])
magdeburg <- read_excel(file_names[6], skip = 4)
magdeburg <- magdeburg[,c(1:18,20,22,24,26,28:37,39,41,43,45:49)]
names(magdeburg) <- var_names
magdeburg <- magdeburg %>%
  mutate(kreis = case_when(
    kreis == "Coburg" ~ "Loburg",
    kreis == "Kalbe / Milde" ~ "Kalbe (Milde)",
    kreis == "Bezirksergebnis" ~ "Bezirk Magdeburg insges",
    TRUE ~ as.character(kreis)
    ))
magdeburg <- magdeburg %>% mutate(across(where(is.character), ~na_if(., "-")))
magdeburg <- type_convert(magdeburg)
magdeburg <- magdeburg %>%  mutate(bezirk = "Magdeburg")

#Nachträglich einfügen der fehlenden LPGs
#Einlesen der Daten
magdeburg_typen <- read_delim(file_lpgs[6], col_types = cols(
  kreis = col_character(),
  bezirk = col_character(),
  lpg_typ_alle = col_double(),
  lpg_typ_1 = col_double(),
  lpg_typ_2 = col_double(),
  lpg_typ_3 = col_double(),
  datum = col_character()  # Erst als Charakter einlesen
)) %>%
#Datum nachträglich als solches umformatieren (geht nicht anders)
  mutate(datum = as.Date(datum, format = "%d.%m.%y"))

anti_join(magdeburg, magdeburg_typen)
anti_join(magdeburg_typen, magdeburg)
magdeburg <- inner_join(magdeburg_typen, magdeburg)

lpgs <- bind_rows(lpgs, magdeburg)
```

```
#---------------
# Karl-Marx-Stadt
#---------------
# vollständig
read_excel(file_names[7])
karl_marx_stadt <- read_excel(file_names[7], skip=4)

# Anzahl der LPG Typen
karl_marx_stadt_typen <- karl_marx_stadt[c(1:25),c(2:4)]
# Ersetze in allen Variablen - durch NA
karl_marx_stadt_typen <- karl_marx_stadt_typen  %>% mutate(across(where(is.character),
~na_if(., "-")))
karl_marx_stadt_typen <- karl_marx_stadt_typen  %>% type_convert()
names(karl_marx_stadt_typen) <- c("lpg_typ_1", "lpg_typ_2", "lpg_typ_3")

karl_marx_stadt <- karl_marx_stadt[c(1:25),c(1,5:21,23,25,27,29,31:40,42,44,46,48:52)]
names(karl_marx_stadt) <- var_names
karl_marx_stadt <- karl_marx_stadt %>%
  mutate(kreis = case_when(
    kreis == 1 ~ "Annaberg",
    kreis == 2 ~ "Aue",
    kreis == 3 ~ "Auerbach",
    kreis == 4 ~ "Brand-Erbisdorf",
    kreis == 5 ~ "Karl-Marx-Stadt-Land",
    kreis == 6 ~ "Flöha",
    kreis == 7 ~ "Freiberg",
    kreis == 8 ~ "Glauchau",
    kreis == 9 ~ "Stollberg",
    kreis == 10 ~ "Hainichen",
    kreis == 11 ~ "Hohenstein-Ernstthal",
    kreis == 12 ~ "Marienberg",
    kreis == 13 ~ "Oelsnitz",
    kreis == 14 ~ "Plauen-Land",
    kreis == 15 ~ "Reichenbach",
    kreis == 16 ~ "Rochlitz",
    kreis == 17 ~ "Schwarzenberg",
    kreis == 18 ~ "Klingenthal",
    kreis == 19 ~ "Werdau",
    kreis == 20 ~ "Zschopau",
    kreis == 21 ~ "Zwickau-Land",
    kreis == 22 ~ "Karl-Marx-Stadt",
    kreis == 23 ~ "Plauen",
    kreis == 24 ~ "Zwickau",
    kreis == 25 ~ "Bezirk Karl-Marx-Stadt insges",
    TRUE ~ as.character(kreis)
    ))
karl_marx_stadt <- karl_marx_stadt %>% mutate(across(where(is.character), ~na_if(., "-")))
karl_marx_stadt <- type_convert(karl_marx_stadt)
karl_marx_stadt <- karl_marx_stadt %>%  mutate(bezirk = "Karl-Marx-Stadt")
karl_marx_stadt <- bind_cols(karl_marx_stadt, karl_marx_stadt_typen)
```

```
#Zusammenaddieren für typ_alle
karl_marx_stadt %>% select(matches("typ")) # Checken
karl_marx_stadt <- karl_marx_stadt %>% mutate(lpg_typ_1 = ifelse(is.na(lpg_typ_1) & (!
is.na(lpg_typ_2 ) | !is.na(lpg_typ_3)),  0, lpg_typ_1))
karl_marx_stadt <- karl_marx_stadt %>% mutate(lpg_typ_3 = ifelse(is.na(lpg_typ_3) & (!
is.na(lpg_typ_1 ) | !is.na(lpg_typ_2)),  0, lpg_typ_3))
karl_marx_stadt <- karl_marx_stadt %>% mutate(lpg_typ_2 = ifelse(is.na(lpg_typ_2) & (!
is.na(lpg_typ_1 ) | !is.na(lpg_typ_3)),  0, lpg_typ_2))
karl_marx_stadt <- karl_marx_stadt %>% mutate(lpg_typ_alle = lpg_typ_1 + lpg_typ_2 +
lpg_typ_3)
karl_marx_stadt %>% select(matches("typ")) # Checken

#Wieder die 0en zu NAs
karl_marx_stadt %>% select(matches("typ"))
karl_marx_stadt <- karl_marx_stadt %>%
  mutate(
    lpg_typ_1 = na_if(lpg_typ_1, 0),
    lpg_typ_2 = na_if(lpg_typ_2, 0),
    lpg_typ_3 = na_if(lpg_typ_3, 0)
  )

lpgs <- bind_rows(lpgs, karl_marx_stadt)

#---------------
# Gera
#---------------
# vollständig
read_excel(file_names[8])
gera <- read_excel(file_names[8], skip=4)
gera <- gera[,c(1:18,20,22,24,26,28:37,39,41,43,45:49)]
names(gera) <- var_names
gera <- gera %>%
  mutate(kreis = case_when(
    kreis == 1 ~ "Eisenberg",
    kreis == 2 ~ "Gera-Land",
    kreis == 3 ~ "Jena-Land",
    kreis == 4 ~ "Lobenstein",
    kreis == 5 ~ "Pößneck",
    kreis == 6 ~ "Rudolstadt",
    kreis == 7 ~ "Saalfeld",
    kreis == 8 ~ "Schleiz",
    kreis == 9 ~ "Stadtroda",
    kreis == 10 ~ "Zeulenroda",
    kreis == 11 ~ "Greiz",
    kreis == 12 ~ "Gera",
    kreis == 13 ~ "Bezirk Gera insges",
    TRUE ~ as.character(kreis)
    ))
gera <- gera %>% mutate(across(where(is.character), ~na_if(., "-")))
```

```
gera <- type_convert(gera)
gera <- gera %>%  mutate(bezirk = "Gera")

#Nachträglich einfügen der fehlenden LPGs
#Einlesen der Daten
gera_typen <- read_delim(file_lpgs[3], col_types = cols(
  kreis = col_character(),
  bezirk = col_character(),
  lpg_typ_alle = col_double(),
  lpg_typ_1 = col_double(),
  lpg_typ_2 = col_double(),
  lpg_typ_3 = col_double(),
  datum = col_character()  # Erst als Charakter einlesen
)) %>%
#Datum nachträglich als solches umformatieren (geht nicht anders)
  mutate(datum = as.Date(datum, format = "%d.%m.%y"))

# Check
anti_join(gera, gera_typen)
anti_join(gera_typen, gera)
gera <- inner_join(gera, gera_typen)

lpgs <- bind_rows(lpgs, gera)

#---------------
# Frankfurt
#---------------
# vollständig
read_excel(file_names[9])
frankfurt <- read_excel(file_names[9], skip=4)

# Anzahl der LPG Typen
frankfurt_typen <- frankfurt[,c(2:5)]
# Ersetze in allen Variablen - durch NA
frankfurt_typen <- frankfurt_typen  %>% mutate(across(where(is.character), ~na_if(., "-")))
frankfurt_typen <- frankfurt_typen  %>% type_convert()
names(frankfurt_typen) <- c("lpg_typ_1", "lpg_typ_2", "lpg_typ_3", "lpg_typ_alle")

frankfurt <- frankfurt[,c(1,6:22,24,26,28,30,32:41,43,45,47,49:53)]
names(frankfurt) <- var_names
frankfurt <- frankfurt %>%
  mutate(kreis = case_when(
    kreis == 1 ~ "Angermünde",
    kreis == 2 ~ "Beeskow",
    kreis == 3 ~ "Bernau",
    kreis == 4 ~ "Eberswalde",
    kreis == 5 ~ "Bad Freienwalde",
    kreis == 6 ~ "Fürstenberg",
    kreis == 7 ~ "Fürstenwalde",
    kreis == 8 ~ "Seelow",
```

```
    kreis == 9 ~ "Strausberg",
    kreis == 10 ~ "Frankfurt an der Oder",
    kreis == 11 ~ "Bezirk Frankfurt insges",
    TRUE ~ as.character(kreis)
    ))
frankfurt <- frankfurt %>% mutate(across(where(is.character), ~na_if(., "-")))
frankfurt <- type_convert(frankfurt)
frankfurt <- frankfurt %>%  mutate(bezirk = "Frankfurt")
frankfurt <- bind_cols(frankfurt, frankfurt_typen)
lpgs <- bind_rows(lpgs, frankfurt)

#---------------
# Erfurt
#---------------
# vollständig
file_names[12]
read_excel(file_names[12])
erfurt <- read_excel(file_names[12], skip=4)
erfurt %>% print(n = 40)
#Kommentar Pana: da die Zahlen für alle LPGs nur vom Oktober vorhanden sind, habe
#ich die bisherigen Zahlen von lpg_typ_alle rausgenommen, da sie nicht übereinstimmen
# Kommentar Moritz:
# Hier haben die Leute bei dem data entry keinen Zwischenraum gelassen zwischen den
# Bezirkssummen pro Typ in Linien 7-9 und den Kreisdaten. Super erkannt hier, dass wir
# den Kram ab Zeile 8 einschliesslich brauchen. Weg mit Zeilen 1-7:
erfurt <- erfurt[-c(1:7),]

# Schmeissen wir alle Spalten raus in denen alle Zellen missing sind
erfurt <- erfurt[,colSums(is.na(erfurt))<nrow(erfurt)]

# Auch die Anzahl der LPG Typen
erfurt <- erfurt[,-2]
names(erfurt) <- var_names

# Jetzt koennen wir die Namen korregieren
erfurt <- erfurt %>%
  mutate(kreis = case_when(
    kreis == 8 ~ "Apolda",
    kreis == 9 ~ "Arnstadt",
    kreis == 10 ~ "Eisenach",
    kreis == 11 ~ "Erfurt-Land",
    kreis == 12 ~ "Gotha",
    kreis == 13 ~ "Heiligenstadt",
    kreis == 14 ~ "Langensalza",
    kreis == 15 ~ "Mühlhausen",
    kreis == 16 ~ "Nordhausen",
    kreis == 17 ~ "Sömmerda",
    kreis == 18 ~ "Sondershausen",
    kreis == 19 ~ "Weimar-Land",
    kreis == 20 ~ "Worbis",
```

```
    kreis == 21 ~ "Erfurt",
    kreis == 22 ~ "Weimar",
    kreis == 23 ~ "Bezirk Erfurt insges",
    TRUE ~ as.character(kreis)
  ))
erfurt <- erfurt %>% mutate(across(where(is.character), ~na_if(., "-")))
erfurt <- type_convert(erfurt)
erfurt <- erfurt %>%  mutate(bezirk = "Erfurt")

#Nachträglich einfügen der fehlenden LPGs
#Einlesen der Daten
erfurt_typen <- read_delim(file_lpgs[2], col_types = cols(
  kreis = col_character(),
  bezirk = col_character(),
  lpg_typ_alle = col_double(),
  lpg_typ_1 = col_double(),
  lpg_typ_2 = col_double(),
  lpg_typ_3 = col_double(),
  datum = col_character()  # Erst als Charakter einlesen
)) %>%
#Datum nachträglich als solches umformatieren (geht nicht anders)
  mutate(datum = as.Date(datum, format = "%d.%m.%y"))

anti_join(erfurt, erfurt_typen)
anti_join(erfurt_typen, erfurt)
erfurt <- inner_join(erfurt, erfurt_typen)

lpgs <- bind_rows(lpgs, erfurt)

#---------------
# Leipzig
#---------------
# vollständig
read_excel(file_names[13])
leipzig <- read_excel(file_names[13], skip=4)

leipzig <- leipzig[,c(1,3:19,21,23,25,27,29:38,40,42,44,46:50)]
names(leipzig) <- var_names
leipzig <- leipzig %>%
 mutate(kreis = case_when(
    is.na(kreis) ~ "Bezirk Leipzig insges",
        kreis == "Land" ~ "Leipzig-Land",
        TRUE ~ as.character(kreis)
        ))
leipzig <- leipzig %>% mutate(across(where(is.character), ~na_if(., "-")))
leipzig <- type_convert(leipzig)
leipzig <- leipzig %>%  mutate(bezirk = "Leipzig")

#Nachträglich einfügen der fehlenden LPGs
#Einlesen der Daten
```

```
leipzig_typen <- read_delim(file_lpgs[5], col_types = cols(
  kreis = col_character(),
  bezirk = col_character(),
  lpg_typ_alle = col_double(),
  lpg_typ_1 = col_double(),
  lpg_typ_2 = col_double(),
  lpg_typ_3 = col_double(),
  datum = col_character()  # Erst als Charakter einlesen
)) %>%
#Datum nachträglich als solches umformatieren (geht nicht anders)
  mutate(datum = as.Date(datum, format = "%d.%m.%y"))

# Check
anti_join(leipzig_typen, leipzig)
anti_join(leipzig, leipzig_typen)
leipzig <- inner_join(leipzig, leipzig_typen)


lpgs <- bind_rows(lpgs, leipzig)

#---------------
# Dresden
#---------------
# vollständig
read_excel(file_names[14])
dresden <- read_excel(file_names[14],skip=4)

#LPGs einfügen
dresden_lpgs <- read_delim(file_lpgs[1], col_types = cols(
  kreis = col_character(),
  bezirk = col_character(),
  lpg_typ_alle = col_double(),
  lpg_typ_1 = col_double(),
  lpg_typ_2 = col_double(),
  lpg_typ_3 = col_double(),
  datum = col_character()  # Erst als Charakter einlesen
)) %>%
  # Datumsspalte jetzt erst richtig konvertieren; anders gehts nicht
  mutate(datum = as.Date(datum, format = "%d.%m.%y"))

# Normale Variablen aussuchen und benennen
dresden <- dresden[c(1:17),c(1:18,20,22,24,26,28:37,39,41,43,45:49)]
names(dresden) <- var_names
dresden <- dresden %>%
 mutate(kreis = case_when(
    kreis == 1 ~ "Bautzen",
    kreis == 2 ~ "Bischofswerda",
    kreis == 3 ~ "Dippoldiswalde",
    kreis == 4 ~ "Dresden-Land",
    kreis == 5 ~ "Freital",
```

```
    kreis == 6 ~ "Görlitz-Land",
    kreis == 7 ~ "Großenhain",
    kreis == 8 ~ "Kamenz",
    kreis == 9 ~ "Löbau",
    kreis == 10 ~ "Meißen",
    kreis == 11 ~ "Niesky",
    kreis == 12 ~ "Pirna",
    kreis == 13 ~ "Riesa",
    kreis == 14 ~ "Sebnitz",
    kreis == 15 ~ "Zittau",
    kreis == 16 ~ "Dresden",
    kreis == 17 ~ "Bezirk Dresden insges",
    TRUE ~ as.character(kreis)
    ))
dresden <- dresden %>% mutate(across(where(is.character), ~na_if(., "-")))
dresden <- type_convert(dresden)
dresden <- dresden %>%  mutate(bezirk = "Dresden")

# Check
anti_join(dresden, dresden_lpgs)
anti_join(dresden_lpgs, dresden)
dresden <- inner_join(dresden, dresden_lpgs)

lpgs <- bind_rows(lpgs, dresden)

#---------------
# Cottbus
#---------------
# vollständig
read_excel(file_names[10])
cottbus <- read_excel(file_names[10],skip=4)

# Anzahl der LPG Typen
cottbus_typen <- cottbus[c(1:15),c(2:5)]
# Ersetze in allen Variablen - durch NA
cottbus_typen <- cottbus_typen  %>% mutate(across(where(is.character), ~na_if(., "-")))
cottbus_typen <- cottbus_typen  %>% type_convert()
names(cottbus_typen) <- c("lpg_typ_alle", "lpg_typ_1", "lpg_typ_2", "lpg_typ_3")

cottbus <- cottbus[c(1:15),c(1,6:22,24,26,28,30,32:41,43,45,47,49:53)]
names(cottbus) <- var_names
cottbus <- cottbus %>%
    mutate(kreis = case_when(
          kreis == "Calan" ~ "Calau",
          kreis == "Luckan" ~ "Luckau",
          kreis == "Bezirk Insgesamt Davon:" ~ "Bezirk Cottbus insges",
          TRUE ~ as.character(kreis)
          ))
cottbus <- cottbus %>% mutate(across(where(is.character), ~na_if(., "-")))
cottbus <- type_convert(cottbus)
```

```
cottbus <- cottbus %>%  mutate(bezirk = "Cottbus")
cottbus$ges_betreu_technisch <- gsub("/.*", "", cottbus$ges_betreu_technisch)
cottbus$ges_betreu_agronomisch <- gsub("/.*", "", cottbus$ges_betreu_agronomisch)
cottbus$ges_betreu_tieraerztlich <- gsub("/.*", "", cottbus$ges_betreu_tieraerztlich)
cottbus$ges_betreu_technisch <- as.double(cottbus$ges_betreu_technisch)
cottbus$ges_betreu_agronomisch <- as.double(cottbus$ges_betreu_agronomisch)
cottbus$ges_betreu_tieraerztlich <- as.double(cottbus$ges_betreu_tieraerztlich)
cottbus <- cottbus %>% mutate(ges_betreu_agronomisch = ifelse(kreis == "Bad
Liebenwerda", 28, ges_betreu_agronomisch))
cottbus <- bind_cols(cottbus, cottbus_typen)
lpgs <- bind_rows(lpgs,cottbus)

#---------------
# Suhl
#---------------
# vollständig
read_excel(file_names[11])
suhl <- read_excel(file_names[11],skip=4)

# Anzahl der LPG Typen
suhl_typen <- suhl[,c(2:4)]
# Ersetze in allen Variablen - durch NA
suhl_typen <- suhl_typen  %>% mutate(across(where(is.character), ~na_if(., "-")))
suhl_typen <- suhl_typen  %>% type_convert()
names(suhl_typen) <- c("lpg_typ_1", "lpg_typ_2", "lpg_typ_3")

suhl <- suhl[,c(1,5:21,23,25,27,29,31:40,42,44,46,48:52)]
names(suhl) <- var_names
suhl <- suhl %>%
      mutate(kreis = case_when(
          kreis == 1 ~ "Bad Salzungen",
          kreis == 2 ~ "Hildburghausen",
          kreis == 3 ~ "Ilmenau",
          kreis == 4 ~ "Neuhaus am Rennweg",
          kreis == 5 ~ "Meiningen",
          kreis == 6 ~ "Schmalkalden",
          kreis == 7 ~ "Sonneberg",
          kreis == 8 ~ "Suhl",
          kreis == 9 ~ "Bezirk Suhl insges",
           TRUE ~ as.character(kreis)
           ))
suhl <- suhl %>% mutate(across(where(is.character), ~na_if(., "-")))
suhl <- type_convert(suhl)
suhl$ges_betreu_technisch <- gsub("/.*", "", suhl$ges_betreu_technisch)
suhl$ges_betreu_agronomisch <- gsub("/.*", "", suhl$ges_betreu_agronomisch)
suhl$ges_betreu_tieraerztlich <- gsub("/.*", "", suhl$ges_betreu_tieraerztlich)
suhl <- type_convert(suhl)
suhl <- suhl %>%  mutate(bezirk = "Suhl")
suhl <- bind_cols(suhl, suhl_typen)
```

```
# Fuellen der NAs und addieren von den Typen
suhl %>% select(matches("typ")) # Checken
suhl <- suhl %>% mutate(lpg_typ_1 = ifelse(is.na(lpg_typ_1) & (!is.na(lpg_typ_2 ) | !
is.na(lpg_typ_3)),  0, lpg_typ_1))
suhl <- suhl %>% mutate(lpg_typ_2 = ifelse(is.na(lpg_typ_2) & (!is.na(lpg_typ_1 ) | !
is.na(lpg_typ_3)),  0, lpg_typ_2))
suhl <- suhl %>% mutate(lpg_typ_3 = ifelse(is.na(lpg_typ_3) & (!is.na(lpg_typ_1 ) | !
is.na(lpg_typ_2)),  0, lpg_typ_3))
suhl <- suhl %>% mutate(lpg_typ_alle = lpg_typ_1 + lpg_typ_2 + lpg_typ_3)
suhl %>% select(matches("typ")) # Checken

#Die 0en wieder zu NAs
suhl %>% select(matches("typ"))
suhl <- suhl %>%
  mutate(
    lpg_typ_1 = na_if(lpg_typ_1, 0),
    lpg_typ_2 = na_if(lpg_typ_2, 0),
    lpg_typ_3 = na_if(lpg_typ_3, 0)
  )

# Auf die anderen Bezirke draufpacken
lpgs <- bind_rows(lpgs,suhl)


# LPG TYPEN
lpgs <- lpgs %>%
  mutate(across(matches("lpg_typ"), ~ ifelse(is.na(.x), 0, .x))) %>%
  mutate(datum = if_else(is.na(datum), dmy("30-06-1953"), datum))

# Sort
lpgs <- lpgs %>% select(kreis, bezirk, names(.))

# Throw out totals
lpgs %>% filter(grepl("insges", kreis)) %>% select(kreis)
lpgs <- lpgs %>% filter(!grepl("insges", kreis))


# Anspielen der 1953 Shapefile codes
lpgs <- ddr %>%
  st_set_geometry(NULL) %>%
  select(kreis = gen, from_code = kreis_kenn) %>%
  inner_join(lpgs, .) %>%
  mutate(from_year = 1953) %>%
  select(kreis, from_code, from_year, names(.)) %>%
  as_tibble()

# Save
#-------------------------------------------------------------------------------
save(lpgs, file = "data/1953-06-30/lpgs.rda")
save(lpgs, file = "/home/moritz/wolke/research/lpg/data/raw/collectivization/lpgs.rda")
```

```
# Codebook
#-------------------------------------------------------------------------------
codebook <- c(
  "kreis" = "Kreisname in 1953 Max Planck Shapefile",
  "from_code" = "Kreis Code in 1953 Max Planck Shapefile",
  "bezirk" = "DDR Bezirk",
  "lpg_typ_alle" = "Anzahl der LPGs",
  "lpg_typ_1" = "Anzahl der LPGs Typ 1",
  "lpg_typ_2" = "Anzahl der LPGs Typ 2",
  "lpg_typ_3" = "Anzahl der LPGs Typ 3",
  "datum" = "Datum"
)
codebook <- data.frame(variables = names(codebook), labels = codebook)

write_csv(codebook, file = "data/1953-06-30/lpgs_codebook.csv")
glimpse(lpgs)
```

```
#=================
# HEKTARERTRAEGE
#=================
# Objective: Clean Hektarertragsdaten
# Authors: Pana & Moritz

# Main tasks:
# Clean the table data contained in "getreide_1966-1973.pdf"

# Delete all objects in your console
rm(list = ls())

# Load libraries
require(tidyverse) # Super Funktionen Sammlung
require(sf) # Fuer Karten und Geodaten
require(janitor) # Um Daten zu saeubern
require(broom) # Um regressionsoutput in datenform zu bringen

# Shapefile mit dt. Landkreisen 1953
#----------------------------------------
# Laden mit dem sf package
ddr_brd <- read_sf("./shapefile_1973/Germany_1973_v.1.0.shp")
# Clean names with function from janitor package
ddr_brd <- clean_names(ddr_brd)
# Visualisieren von BRD und DDR in 1953, Faerbung ist Groesse des
Kreisesplot(ddr_brd["area"])
# In Deutschland hat jede Gemeinde einen Code mit 8 Stellen (Wiki: Allgemeiner
Gemeindeschluessel, kurz AGS)
# Die ersten 5 Stellen sind fuer die Kreise, die ersten 2 fuer Bundeslaender
# Berlin ist 11, die andern Oestlichen Bundeslaender haben 12 bis 16
# Kodiere Variable mit Bundesland Schluesseln
ddr_brd <- ddr_brd %>%  mutate(bula_kenn = substr(kreis_kenn, 0,2))
# Nur die DDR
ddr <- ddr_brd %>% filter(bula_kenn %in% c(11:16))
plot(ddr["bula_kenn"])

# In der DDR wurde allerdings in anderes Schluesselsystem benutzt. Es gab auch die
Bundeslaender nicht mehr.
# Das System kommt aus der BRD und wurde in diesem Shapefile vom Max Planck Inst.
rueckwaertsgewandt auf die DDR uebertragen.

# FRAGE: SOLLEN WIR STADT UND LAND ZUSAMMEN FUEHREN?
# Manche Kreise haben die gleichen Namen sollen aber Standt und Land sein. Mergen!
# ddr %>% group_by(gen) %>% filter(n()>1)
# ddr %>% filter(gen == "Neubrandenburg") %>% ggplot()+ geom_sf()
# ddr %>% filter(gen == "Suhl") %>% ggplot()+ geom_sf()
# ddr %>% filter(gen == "Cottbus") %>% ggplot()+ geom_sf()
#
# # Merge sf polyons grouped by gen
# ddr <- ddr %>%
```

```
#   group_by(gen, kreis_id) %>%
#   summarise(area = sum(area),
#             perimeter = max(perimeter),
#             bula_kenn = first(bula_kenn)) %>%
#   ungroup() %>%
#   st_make_valid()
# ddr %>% filter(gen == "Neubrandenburg") %>% ggplot()+ geom_sf()
# ddr %>% filter(gen == "Suhl") %>% ggplot()+ geom_sf()

# Speichern aller Kreisnamen in einem data frame
glimpse(ddr)
kreise <- ddr %>% st_set_geometry(NULL) %>% select(bula_kenn, gen) %>%
arrange(bula_kenn)

# Das sind alle Kreise in der DDR in 1953
kreise %>% print(n=300)
# Koenntest Du die Kreisnamen weiter unten damit harmonisieren? Wird gemacht!

# Mit dieser Funktion kannst Du einen beliebigen Kreis auswaehlen und visualisieren
visualize_kreis = function(kreis) {
  ddr %>%
    mutate(label = ifelse(gen == kreis, gen, NA_character_)) %>%
    ggplot(aes(label = label, color = bula_kenn)) + geom_sf() + geom_sf_label() +
theme_void()
}
visualize_kreis("Fürstenberg")

# SPREADSHEETS
#-----------------
# Load all files in the directory
file_names <- list.files(path = "./output_1973")
# Sort using integers inside string
file_names <- file_names[order(as.integer(gsub("\\D", "", file_names)))]
file_names

# Each file corresponds to one page of the original PDF.
# The files ending with confidence contain a measure of how confident the digiiization was.
file_names_conf <- file_names %>% str_subset("confidence")
file_names_data <- file_names %>% str_subset("1973.csv")

# Lade alle csv Dateien in eine Liste mit jeder Spalte als character
data <- map(file_names_data, ~ read_csv(paste0("./output_1973/", .x),
                                col_types = cols(.default = col_character())))

# data ist eine liste mit dataframes mit dimensionen:
map(data, ~dim(.x))
```

```
# STRUKTUR DES DOKUMENTES
#=========================
# Seiten 1-2 wurden nicht digitalisiert
# Seiten 3-4 sind pro Bezirk
# Seiten 5-ende sind pro Kreis
# Jeweils immer zwei Seiten: Einmal Weizen & Co und dann Kartoffeln & Co

# Get all even numbers in the range 5-30
evens <- function(x) subset(x, x %% 2 == 0)
even_range = evens(1:30)

# odd numbers in the range 5-30
odd_range = even_range - 1
odd_range

getreide <- data[odd_range]
kartoffeln <- data[even_range]
rm(data)

# GETREIDE
#---------
# Schauen wir uns zuerst Weizen an.
map(getreide, ~ dim(.x))

# Erstes Blatt mit Bezirksergebnissen nehmen wir gar nicht
getreide[[1]] <- NULL


# Variablennamen
getreide_namen <- c(
  # Davon weizen, roggen, gerste, gerste? einschliesslich Koernermais
  "getreide_1966_1970", "getreide_1972", "getreide_1973",
  "winterweizen_1972", "winterweizen_1973", "winterrogen_1972", "winterrogen_1973",
  "wintergerste_1972", "wintergerste_1973", "sommergerste_1972", "sommergerste_1973",
  "winterraps_1966_1970", "winterraps_1972", "winterraps_1973") %>%
  paste0(., "_dtha") %>%
  c("kreis", .)

# Ersten 5 Zeilen abschneiden
getreide <- map(getreide, ~.x %>% slice(-c(1:5)))

# Namen drauf und dann alles zusammenkleben
getreide <- map(getreide, ~.x %>% set_names(getreide_namen))

# Alles zusammenkleben
getreide <- bind_rows(getreide)

# Jeden Bindestrich als missing
getreide <- getreide %>% mutate(across(everything(), ~ifelse(trimws(.x) == "-",
NA_character_, .x)))
```

```
# Kommas durch punkte ersetzen
getreide <- getreide %>% mutate(across(everything(), ~gsub("\\,", ".", .x)))

# Hier und da gibt es noch zb quotation marks
getreide <- getreide %>% mutate(across(everything(), ~gsub('\\"', "", .x)))

# Alle vars als numerisch
getreide <- getreide %>% type_convert()

# Buchstaben noch weg
getreide <- getreide %>% mutate(across(getreide_1966_1970_dtha:winterraps_1973_dtha,
~gsub('[a-zA-Z]', "", .x)))

# Und wenn bindestrich irgendwo dann weg
getreide <- getreide %>% mutate(across(getreide_1966_1970_dtha:winterraps_1973_dtha,
                                ~ifelse(grepl("\\-", .x), NA_character_, .x)))
getreide <- getreide %>% type_convert()
# Voila!

# Schmeissen wir die Bezirk insgesamt zeilen raus
getreide <- getreide %>% filter(!grepl("bezirk|insgesamt|DDR", kreis, ignore.case = T))

# Keine Leerzeichen um das wort herum
getreide <- getreide %>% mutate(kreis = trimws(kreis))

# Checken ob Getreide einzigartige namen hat?
getreide %>% distinct(kreis)

# KARTOFFELN ETC
#---------------
# Schauen wir uns zuerst Weizen an.
map(kartoffeln, ~ dim(.x))

# Erste spalte wegschmeissen im ersten
# kartoffeln[[1]] <- kartoffeln[[1]][,-1]
# map(kartoffeln, ~ dim(.x))

# Erstes Blatt mit Bezirksergebnissen nehmen wir gar nicht
kartoffeln[[1]] <- NULL

# Variablennamen
kartoffel_namen <- c(
  "kartoffeln_1966_1970", "kartoffeln_1972", "kartoffeln_1973",
  "zuckerrueben_1966_1970", "zuckerrueben_1972", "zuckerrueben_1973",
  "futterhackfruechte_1972", "futterhackfruechte_1973",
  "gruen_silomais_1972", "gruen_silomais_1973",
  "wiesenheu_1966_1970", "wiesenheu_1972", "wiesenheu_1973",
  "feldfutterpflanzen_1972", "feldfutterpflanzen_1973") %>%   # Ohne Mais
  paste0(., "_dtha") %>%
```

```
  c("kreis", .)


# Ersten 5 Zeilen abschneiden
map(kartoffeln, ~ head(.x))
kartoffeln <- map(kartoffeln, ~.x %>% slice(-c(1:4)))

# Namen drauf und dann alles zusammenkleben
kartoffeln <- map(kartoffeln, ~.x %>% set_names(kartoffel_namen)) %>% bind_rows()

# Jeden Bindestrich als missing
kartoffeln <- kartoffeln %>% mutate(across(everything(), ~ifelse(trimws(.x) == "-",
NA_character_, .x)))

# Kommas durch punkte ersetzen
kartoffeln <- kartoffeln %>% mutate(across(everything(), ~gsub("\\,", ".", .x)))

# Alle vars als numerisch
kartoffeln <- kartoffeln %>% type_convert()

# Hier und da gibt es noch zb quotation marks
kartoffeln <- kartoffeln %>% mutate(across(everything(), ~gsub('\\"|\\*', "", .x)))

# Alle vars als numerisch
kartoffeln <- kartoffeln %>% type_convert()

# Buchstaben noch weg
kartoffeln <- kartoffeln %>%
mutate(across(kartoffeln_1966_1970_dtha:feldfutterpflanzen_1973_dtha, ~gsub('[a-zA-Z]',
"", .x)))

# Und wenn bindestrich irgendwo dann weg
kartoffeln <- kartoffeln %>%
mutate(across(kartoffeln_1966_1970_dtha:feldfutterpflanzen_1973_dtha,
                                ~ifelse(grepl("\\-", .x), NA_character_, .x)))
kartoffeln <- kartoffeln %>% type_convert()

# Rest forcen wir als NA
kartoffeln <- kartoffeln %>%
mutate(across(kartoffeln_1966_1970_dtha:feldfutterpflanzen_1973_dtha,
                                  ~ as.numeric(.)))
# Schmeissen wir die Bezirk insgesamt zeilen raus
kartoffeln <- kartoffeln %>% filter(!grepl("bezirk|bazirk|insgesamt|DDR|D D R", kreis,
ignore.case = T))

# Keine Leerzeichen um das wort herum
kartoffeln <- kartoffeln %>% mutate(kreis = trimws(kreis))

# Kreis checken
kartoffeln %>% distinct(kreis)
```

```
# HARMONISIERUNG DER KREISNAMEN
#-------------------------------
# Alle Namen sammeln aus den Daten
kreis_schreibweisen <- data.frame(kreis_ertragsdaten = unique(getreide$kreis,
kartoffeln$kreis)) %>% as_tibble()

# Korrespondenz zum shapefile
kreis_schreibweisen <- ddr %>%
  distinct(gen) %>%
  mutate(kreis_shapefile = gen) %>%
  left_join(kreis_schreibweisen, ., by = c("kreis_ertragsdaten" = "gen"))
kreis_schreibweisen

# Korrespondenz zu ertragsdaten
ddr %>%
  distinct(gen) %>%
  mutate(kreis_shapefile = gen) %>%
  anti_join(., kreis_schreibweisen, ., by = c("gen"="kreis_ertragsdaten")) %>%
  arrange(gen) %>%
  print(n=100)

# Dort wo kreis_shapefile missing ist muessen wir den richtigen Namen eintragen
kreis_schreibweisen %>% print(n = 300)
kreis_schreibweisen %>% filter(is.na(kreis_shapefile)) %>% print(n = 300)

# Hier sind die richtigen Namen
ddr %>% group_by(gen) %>% filter(n()>1)
ddr %>% distinct(gen)
ddr %>% select(gen) %>% View()

# Korrespondenz bitte per Hand matchen!
kreis_schreibweisen <- kreis_schreibweisen %>%
  mutate(kreis_shapefile = case_when(
    kreis_ertragsdaten == "Noubrandenburg" ~ "Neubrandenburg",
    # Wenn Frankfurt in dem Namen ist
    grepl("Frankfurt", kreis_ertragsdaten) ~ "Frankfurt an der Oder",
    kreis_ertragsdaten == "Hallo" ~ "Halle",
    kreis_ertragsdaten == "Leipsig" ~ "Leipzig",
    kreis_ertragsdaten == "Harl-Marx-Stadt" ~ "Karl-Marx-Stadt",
    kreis_ertragsdaten == "Hauptstadt Berlin" ~ "Berlin Ost",
    kreis_ertragsdaten == "Grevesmillen" ~ "Grevesmühlen",
    kreis_ertragsdaten == "Ribnitz" ~ "Ribnitz-Damgarten",
    kreis_ertragsdaten == "Rugen" ~ NA_character_,
    kreis_ertragsdaten == "Butzow" ~ "Bützow",
    kreis_ertragsdaten == "Liibz" ~ "Lübz",
    kreis_ertragsdaten == "Demnin" ~ "Demmin",
    kreis_ertragsdaten == "Noustrelitz" ~ "Neustrelitz",
    kreis_ertragsdaten == "Robol" ~ "Röbel/Müritz",
    kreis_ertragsdaten == "UeckermUnde" ~ "Ueckermünde",
    kreis_ertragsdaten == "Juterbog" ~ "Jüterbog",
```

```
    kreis_ertragsdaten == "Konigs Wusterhausen" ~ "Königs-Wusterhausen",
    kreis_ertragsdaten == "Luckenvalde" ~ "Luckenwalde",
    kreis_ertragsdaten == "Angermunde" ~ "Angermünde",
    kreis_ertragsdaten == "Eisenhüttenstadt" ~ "Fürstenberg", #
    kreis_ertragsdaten == "Furstenwalde" ~ "Fürstenwalde",
    kreis_ertragsdaten == "Liebenwerda" ~ "Bad Liebenwerda",
    kreis_ertragsdaten == "Lubben" ~ "Lübben",
    kreis_ertragsdaten == "Kalbe/N" ~ "Kalbe (Milde)",
    kreis_ertragsdaten == "Klotze" ~ "Klötze",
    kreis_ertragsdaten == "Tangerhutte" ~ "Tangerhütte",
    kreis_ertragsdaten == "Bad Langensalza" ~ NA_character_,
    kreis_ertragsdaten == "Muhlheusen" ~ "Mühlhausen",
    kreis_ertragsdaten == "Sommerda" ~ "Sömmerda",
    kreis_ertragsdaten == "Erfurt-Stadt" ~ "Erfurt",
    kreis_ertragsdaten == "poßneck" ~ "Pößneck",
    kreis_ertragsdaten == "Bad Salsungen" ~ "Bad Salzungen",
    kreis_ertragsdaten == "Neuhaus" ~ "Neuhaus am Rennweg",
    kreis_ertragsdaten == "Schmallcalden" ~ "Schmalkalden",
    kreis_ertragsdaten == "Dippoldisvalde" ~ "Dippoldiswalde",
    kreis_ertragsdaten == "Gorlitz" ~ "Görlitz",
    kreis_ertragsdaten == "GroBenhain" ~ "Großenhain",
    kreis_ertragsdaten == "Lobau" ~ "Löbau",
    kreis_ertragsdaten == "Wer&au" ~ "Werdau",
    kreis_ertragsdaten == "Hohenstein/E." ~ "Hohenstein-Ernstthal",
    kreis_ertragsdaten == "Floha" ~ "Flöha",
    kreis_ertragsdaten == "Brand-E." ~ "Brand-Erbisdorf",
    kreis_ertragsdaten == "Rugen" ~ "Rügen",
    kreis_ertragsdaten == "Brandenburg" ~ "Brandenburg-Land",
    kreis_ertragsdaten == "Bad Langensalza" ~ "Langensalza",
    TRUE ~ kreis_shapefile
  ))

kreis_schreibweisen %>% filter(is.na(kreis_shapefile)) %>% print(n = 300)
kreis_schreibweisen
kreis_schreibweisen <- kreis_schreibweisen %>%
  filter(!is.na(kreis_shapefile))
kreis_schreibweisen

# An die Ertragsdaten dranhaengen
kartoffeln <- inner_join(kreis_schreibweisen, kartoffeln, by = c("kreis_ertragsdaten" =
"kreis")) %>%
  select(-kreis_ertragsdaten) %>%
  rename(kreis = kreis_shapefile)
kartoffeln

getreide <- inner_join(kreis_schreibweisen, getreide, by = c("kreis_ertragsdaten" = "kreis"))
%>%
  select(-kreis_ertragsdaten) %>%
  rename(kreis = kreis_shapefile)
```

```
# Kreiskennzahl (AGS) dranhaengen
kartoffeln <- ddr %>%
  select(gen, kreis_kenn) %>%
  inner_join(kartoffeln, ., by = c("kreis" = "gen")) %>%
  select(kreis, kreis_kenn, everything())

# Da fuer Cottbust Stadt und Land nicht unterschieden wird gibt es die jetzt zwei mal
kartoffeln %>% group_by(kreis) %>% filter(n()>1)

getreide <- ddr %>%
  select(gen, kreis_kenn) %>%
  inner_join(getreide, ., by = c("kreis" = "gen")) %>%
  select(kreis, kreis_kenn, everything())

getreide %>% group_by(kreis) %>% filter(n()>1)
getreide

# Ertragsdaten zusammen bringen auf Ebene der gecleanten Kreisnahmen
ertraege <- full_join(getreide, kartoffeln)
ertraege %>% group_by(kreis) %>% filter(n()>1)

save(ertraege, file = "hektarertraege_1973.Rda")
```

#On agricultural output in Nazi-Germany

```
#==============================================================
# MATCHING OF KREIS NAMES BETWEEN HARVEST DATA TOPICS
#==============================================================
#1939

# Workflow:
rm(list = ls())

library(tidyverse)
library(readODS)
library(janitor)
library(cli)
library(sf)
library(fuzzyjoin)
library(leaflet)

# Functions
#———————————————-
# Replace NA with "" when pasting
paste2 <- function(...,sep="") {
  L <- list(...)
  L <- lapply(L,function(x) {x[is.na(x)] <- ""; x})
  gsub(paste0("(^",sep,"|",sep,"$)"),"",
       gsub(paste0(sep,sep),sep,
            do.call(paste,c(L,list(sep=sep)))))
}


clean_district_name = function(df, kreis_var){

  df <-   df %>%
    mutate(kreis_string = !!sym(kreis_var)) %>%
    mutate(kreis_string = tolower(kreis_string), #namen standardisieren
           kreis_string = gsub("-", " ", kreis_string),
           kreis_string = gsub("[[:punct:]]", "", kreis_string),
           kreis_string = gsub("\\s+", " ", kreis_string))

  return(df)
}
```

```
# HARVEST DATA
#==================
load("1939_1940_1941_1943/R 3102_10957/harvest_1939_raw.rda")

# Duplicate names in districts
harvest_1939[[1]] %>% group_by(kreis) %>% filter(n() > 1) %>% print(n = 500)
harvest_1939[[2]] %>% group_by(kreis) %>% filter(n() > 1) %>% print(n = 500)
harvest_1939[[3]] %>% group_by(kreis) %>% filter(n() > 1) %>% print(n = 500)
harvest_1939[[4]] %>% group_by(kreis) %>% filter(n() > 1) %>% print(n = 500)
# -> Will be cleaned by hand!

# Bind all Kreisnames together
kreis_names <- bind_rows(
  select(harvest_1939[[1]], provinz, regierungsbezirk, kreis),
  select(harvest_1939[[2]], provinz, regierungsbezirk, kreis),
  select(harvest_1939[[3]], provinz, regierungsbezirk, kreis),
  select(harvest_1939[[4]], provinz, regierungsbezirk, kreis)) %>%
  clean_district_name(df = ., kreis_var = "kreis") %>%
  arrange(kreis_string) %>%
  # Some cleaning
  mutate(kreis_string = trimws(gsub("hansestadt", "", kreis_string))) %>%
  group_by(kreis_string) %>%
  mutate(nr = n()) %>%
  ungroup() %>%
  mutate(kreis_clean = kreis_string)

kreis_names %>%
  select(-provinz) %>%
  filter(nr != 4) %>%
  print(n = 500)

kreis_names <- kreis_names %>%
  mutate(kreis_clean = case_when(
    kreis_string == "aurich ostfriesland" ~ "aurich",
    kreis_string == "bartenstein" ~ "bartenstein ostpr",
    kreis_string == "dramburg" ~ "dramsburg",
    kreis_string == "friedberg" & regierungsbezirk == "Hessen" ~ "friedberg hessen",
    kreis_string == "gmünd" & regierungsbezirk == "Jagstbezirk" ~ "gmünd jagstbezirk",
    kreis_string == "lindau a d isar" ~ "landau a d isar",
    kreis_string == "gießen" ~ "giessen",
    kreis_string == "gießen stadt" ~ "giessen stadt",
    kreis_string == "waidhofen an der thaya" ~ "waidhofen an der moldau",
    TRUE ~ kreis_string
  )) %>%
  group_by(kreis_clean) %>%
  mutate(nr = n()) %>%
  ungroup()

kreis_names %>%
  select(-provinz) %>%
```

```
  filter(nr != 4) %>%
  print(n = 500)

# UNIFORMIZE PROVINZ AND REGIERUNGSBEZIRK OVER CLEAN NAMES
kreis_names <- kreis_names %>%
  select(data_kreis_clean = kreis_clean, data_kreis_orig = kreis,
         data_provinz_orig = provinz, data_regierungsbezirk_orig = regierungsbezirk) %>%
  group_by(data_kreis_clean) %>%
  mutate(id = row_number()) %>%
  mutate(data_regierungsbezirk = ifelse(id == 1, data_regierungsbezirk_orig, NA),
         data_provinz = ifelse(id == 1, data_provinz_orig, NA)) %>%
  fill(c(data_regierungsbezirk, data_provinz), .direction = "downup") %>%
  ungroup() %>%
  distinct(data_kreis_clean, data_provinz, data_regierungsbezirk,
           data_provinz_orig, data_regierungsbezirk_orig, data_kreis_orig)


# DEFINE STADT & LAND
kreis_names_stadt <- kreis_names %>%
  distinct(data_kreis_clean,  data_regierungsbezirk) %>%
  mutate(data_kreis_clean_stadt = trimws(gsub("\\bstadt\\b", "", data_kreis_clean))) %>%
  group_by(data_kreis_clean_stadt) %>%
  mutate(nr = n()) %>%
  mutate(stadt_land = ifelse(grepl("\\bstadt\\b",data_kreis_clean), "stadt", NA_character_))
%>%
  fill(stadt_land, .direction = "downup") %>%
  ungroup()

# !!! All remaining duplicates are either Stadt or Land
kreis_names_stadt %>%
  filter(nr > 1) %>%
  print(n = 500)

kreis_names_stadt <- kreis_names_stadt %>%
  filter(nr > 1) %>%
  mutate(data_kreis_clean_stadt_land = ifelse(grepl("\\bstadt\\b",data_kreis_clean) & nr > 1,
data_kreis_clean,
                                        paste0(data_kreis_clean, " land"))) %>%
  select(data_kreis_clean, data_kreis_clean_stadt_land, data_regierungsbezirk)
kreis_names_stadt

# Add back to kreis_names
kreis_names <- kreis_names %>%
  left_join(kreis_names_stadt) %>%
  mutate(data_kreis_clean = ifelse(is.na(data_kreis_clean_stadt_land),
                                   data_kreis_clean, data_kreis_clean_stadt_land)) %>%
  select(-data_kreis_clean_stadt_land) %>%
  rename(provinz = data_provinz_orig, regierungsbezirk = data_regierungsbezirk_orig, kreis
= data_kreis_orig)
kreis_names
```

```
# LINK BACK TO HARVEST TO UNIFORMIZE DISTRICT NAMES
# Sanity checks
anti_join(harvest_1939[[1]], kreis_names)
anti_join(harvest_1939[[2]], kreis_names)
anti_join(harvest_1939[[3]], kreis_names)
anti_join(harvest_1939[[4]], kreis_names)

harvest_1939[[1]] <- inner_join(harvest_1939[[1]], kreis_names) %>%
  select(-provinz, -regierungsbezirk, -kreis, -typ, -page, -file_name) %>%
  select(matches("data"), names(.))
harvest_1939[[2]] <- inner_join(harvest_1939[[2]], kreis_names) %>%
  select(-provinz, -regierungsbezirk, -kreis, -typ, -page, -file_name) %>%
  select(matches("data"), names(.))
harvest_1939[[3]] <- inner_join(harvest_1939[[3]], kreis_names) %>%
  select(-provinz, -regierungsbezirk, -kreis, -typ, -page, -file_name) %>%
  select(matches("data"), names(.))
harvest_1939[[4]] <- inner_join(harvest_1939[[4]], kreis_names) %>%
  select(-provinz, -regierungsbezirk, -kreis, -typ, -page, -file_name) %>%
  select(matches("data"), names(.))

glimpse(harvest_1939[[4]])

harvest_1939 <- harvest_1939[[1]] %>%
  full_join(harvest_1939[[2]]) %>%
  full_join(harvest_1939[[3]]) %>%
  full_join(harvest_1939[[4]])

harvest_1939 %>% dim()
harvest_1939 %>% distinct(data_kreis_clean) %>% dim()
harvest_1939

# Clean numeric variables!!!
#==========================
harvest_1939 <- harvest_1939 %>%
  mutate(across(!matches("data_"), \(x) gsub("[[:punct:]&&[^,.]]", "", x))) %>%
  mutate(across(!matches("data_"), \(x) gsub(",", ".", x))) %>%
  mutate(across(!matches("data_"), \(x) gsub("[[:alpha:]]", "", x))) %>%
  mutate(across(!matches("data_"), \(x) trimws(gsub("\\s+", "", x)))) %>%
  mutate(across(!matches("data_"), \(x) as.numeric(x)))

save(harvest_1939, file = "1939_1940_1941_1943/R 3102_10957/
harvest_1939_clean_names.rda")
```

#==========
 # MATCHING OF KREIS NAMES BETWEEN HARVEST DATA TOPICS
#==========
1940

```
# Workflow:
rm(list = ls())

library(tidyverse)
library(readODS)
library(janitor)
library(cli)
library(sf)
library(fuzzyjoin)
library(leaflet)

# Functions
source(file = "1939_1940_1941_1943/matching_helper_functions.R")

# HARVEST DATA
#==================
load("1939_1940_1941_1943/R 3102_10926/harvest_1940_raw.rda")


# DUPLICATE KREIS NAMES IN DIFFERENT PROVINCES
# Duplicate names in districts
harvest_1940[[1]] %>% group_by(kreis) %>% filter(n() > 1) %>% print(n = 500)
harvest_1940[[2]] %>% group_by(kreis) %>% filter(n() > 1) %>% print(n = 500)
harvest_1940[[3]] %>% group_by(kreis) %>% filter(n() > 1) %>% print(n = 500)
harvest_1940[[4]] %>% group_by(kreis) %>% filter(n() > 1) %>% print(n = 500)
# -> Will be cleaned by hand!

# Bind all Kreisnames together
kreis_names <- bind_rows(
  select(harvest_1940[[1]], provinz, regierungsbezirk, kreis),
  select(harvest_1940[[2]], provinz, regierungsbezirk, kreis),
  select(harvest_1940[[3]], provinz, regierungsbezirk, kreis),
  select(harvest_1940[[4]], provinz, regierungsbezirk, kreis)) %>%
  clean_district_name(df = ., kreis_var = "kreis") %>%
  arrange(kreis_string) %>%
  # Some cleaning
  mutate(kreis_string = trimws(gsub("hansestadt", "", kreis_string))) %>%
  group_by(kreis_string) %>%
  mutate(nr = n()) %>%
  ungroup() %>%
  mutate(kreis_clean = kreis_string)

kreis_names %>%
  select(-provinz) %>%
  filter(nr != 4) %>%
  print(n = 500)
```

```
kreis_names <- kreis_names %>%
  mutate(kreis_clean = case_when(
    kreis_string == "aurich ostfriesland" ~ "aurich",
    kreis_string == "bartenstein" ~ "bartenstein ostpr",
    kreis_string == "dramburg" ~ "dramsburg",
    kreis_string == "friedberg" & regierungsbezirk == "Hessen" ~ "friedberg hessen",
    kreis_string == "gmünd" & regierungsbezirk == "Jagstbezirk" ~ "gmünd jagstbezirk",
    kreis_string == "lindau a d isar" ~ "landau a d isar",
    kreis_string == "gießen" ~ "giessen",
    kreis_string == "gießen stadt" ~ "giessen stadt",
    kreis_string == "waidhofen an der thaya" ~ "waidhofen an der moldau",
    TRUE ~ kreis_string
  )) %>%
  group_by(kreis_clean) %>%
  mutate(nr = n()) %>%
  ungroup()

kreis_names %>%
  select(-provinz) %>%
  filter(nr != 4) %>%
  print(n = 500)

# UNIFORMIZE PROVINZ AND REGIERUNGSBEZIRK OVER CLEAN NAMES
kreis_names <- kreis_names %>%
  select(data_kreis_clean = kreis_clean, data_kreis_orig = kreis,
         data_provinz_orig = provinz, data_regierungsbezirk_orig = regierungsbezirk) %>%
  group_by(data_kreis_clean) %>%
  mutate(id = row_number()) %>%
  mutate(data_regierungsbezirk = ifelse(id == 1, data_regierungsbezirk_orig, NA),
         data_provinz = ifelse(id == 1, data_provinz_orig, NA)) %>%
  fill(c(data_regierungsbezirk, data_provinz), .direction = "downup") %>%
  ungroup() %>%
  distinct(data_kreis_clean, data_provinz, data_regierungsbezirk,
           data_provinz_orig, data_regierungsbezirk_orig, data_kreis_orig)
kreis_names

# DEFINE STADT & LAND
kreis_names_stadt <- kreis_names %>%
  distinct(data_kreis_clean,  data_regierungsbezirk) %>%
  mutate(data_kreis_clean_stadt = trimws(gsub("\\bstadt\\b", "", data_kreis_clean))) %>%
  group_by(data_kreis_clean_stadt) %>%
  mutate(nr = n()) %>%
  mutate(stadt_land = ifelse(grepl("\\bstadt\\b",data_kreis_clean), "stadt", NA_character_))
%>%
  fill(stadt_land, .direction = "downup") %>%
  ungroup()
```

```
# !!! All remaining duplicates are either Stadt or Land
kreis_names_stadt %>%
  filter(nr > 1) %>%
  print(n = 500)

kreis_names_stadt <- kreis_names_stadt %>%
  filter(nr > 1) %>%
  mutate(data_kreis_clean_stadt_land = ifelse(grepl("\\bstadt\\b",data_kreis_clean) & nr > 1,
data_kreis_clean,
                                        paste0(data_kreis_clean, " land"))) %>%
  select(data_kreis_clean, data_kreis_clean_stadt_land, data_regierungsbezirk)
kreis_names_stadt %>%
  print(n = 200)


# Add back to kreis_names
kreis_names <- kreis_names %>%
  left_join(kreis_names_stadt) %>%
  mutate(data_kreis_clean = ifelse(is.na(data_kreis_clean_stadt_land),
                                   data_kreis_clean, data_kreis_clean_stadt_land)) %>%
  select(-data_kreis_clean_stadt_land) %>%
  rename(provinz = data_provinz_orig, regierungsbezirk = data_regierungsbezirk_orig, kreis
= data_kreis_orig)


# LINK BACK TO HARVEST TO UNIFORMIZE DISTRICT NAMES
# Sanity checks
anti_join(harvest_1940[[1]], kreis_names)
anti_join(harvest_1940[[2]], kreis_names)
anti_join(harvest_1940[[3]], kreis_names)
anti_join(harvest_1940[[4]], kreis_names)

harvest_1940[[1]] <- inner_join(harvest_1940[[1]], kreis_names) %>%
  select(-provinz, -regierungsbezirk, -kreis, -typ, -page, -file_name) %>%
  select(matches("data"), names(.))
harvest_1940[[2]] <- inner_join(harvest_1940[[2]], kreis_names) %>%
  select(-provinz, -regierungsbezirk, -kreis, -typ, -page, -file_name) %>%
  select(matches("data"), names(.))
harvest_1940[[3]] <- inner_join(harvest_1940[[3]], kreis_names) %>%
  select(-provinz, -regierungsbezirk, -kreis, -typ, -page, -file_name) %>%
  select(matches("data"), names(.))
harvest_1940[[4]] <- inner_join(harvest_1940[[4]], kreis_names) %>%
  select(-provinz, -regierungsbezirk, -kreis, -typ, -page, -file_name) %>%
  select(matches("data"), names(.))

#Joining with `by = join_by(provinz, regierungsbezirk, kreis)`
harvest_1940[[1]] %>%
  distinct(data_kreis_clean)
```

```
harvest_1940 <- harvest_1940[[1]] %>%
  full_join(harvest_1940[[2]]) %>%
  full_join(harvest_1940[[3]]) %>%
  full_join(harvest_1940[[4]])

harvest_1940 %>% dim()
harvest_1940 %>% distinct(data_kreis_clean) %>% dim()

harvest_1940 %>%
  arrange(data_kreis_clean) %>%
  group_by(data_kreis_clean) %>%
  filter(n() > 1) %>%
  print(n = 200)

save(harvest_1940, file = "1939_1940_1941_1943/R 3102_10926/
harvest_1940_clean_names.rda")
```

```
#==============================================================
# MATCHING OF KREIS NAMES BETWEEN HARVEST DATA TOPICS
#==============================================================
# 1941
rm(list = ls())

library(tidyverse)
library(readODS)
library(janitor)
library(cli)
library(sf)
library(fuzzyjoin)
library(leaflet)

# Functions
#-------------------
source("1939_1940_1941_1943/matching_helper_functions.R")


# HARVEST DATA
#==================
load("1939_1940_1941_1943/R 3102_10959/harvest_1941_raw.rda")


# Duplicate names in districts
harvest_1941[[1]] %>% group_by(kreis) %>% filter(n() > 1) %>% print(n = 500)
harvest_1941[[2]] %>% group_by(kreis) %>% filter(n() > 1) %>% print(n = 500)
harvest_1941[[3]] %>% group_by(kreis) %>% filter(n() > 1) %>% print(n = 500)
harvest_1941[[4]] %>% group_by(kreis) %>% filter(n() > 1) %>% print(n = 500)
# -> Will be cleaned by hand!

# Bind all Kreisnames together
kreis_names <- bind_rows(
  select(harvest_1941[[1]], provinz, regierungsbezirk, kreis),
  select(harvest_1941[[2]], provinz, regierungsbezirk, kreis),
  select(harvest_1941[[3]], provinz, regierungsbezirk, kreis),
  select(harvest_1941[[4]], provinz, regierungsbezirk, kreis)) %>%
  clean_district_name(df = ., kreis_var = "kreis") %>%
  arrange(kreis_string) %>%
  # Some cleaning
  mutate(kreis_string = trimws(gsub("hansestadt", "", kreis_string))) %>%
  group_by(kreis_string) %>%
  mutate(nr = n()) %>%
  ungroup() %>%
  mutate(kreis_clean = kreis_string)


kreis_names %>%
  select(-provinz) %>%
  filter(nr != 4) %>%
```

```
  print(n = 500)

kreis_names <- kreis_names %>%
  mutate(kreis_clean = case_when(
    kreis_string == "aurich ostfriesland" ~ "aurich",
    kreis_string == "bartenstein" ~ "bartenstein ostpr",
    kreis_string == "dramburg" ~ "dramsburg",
    kreis_string == "friedberg" & regierungsbezirk == "Hessen" ~ "friedberg hessen",
    kreis_string == "gmünd" & regierungsbezirk == "Jagstbezirk" ~ "gmünd jagstbezirk",
    kreis_string == "lindau a d isar" ~ "landau a d isar",
    kreis_string == "gießen" ~ "giessen",
    kreis_string == "gießen stadt" ~ "giessen stadt",
    kreis_string == "waidhofen an der thaya" ~ "waidhofen an der moldau",
    TRUE ~ kreis_string
  )) %>%
  group_by(kreis_clean) %>%
  mutate(nr = n()) %>%
  ungroup()

kreis_names %>%
  select(-provinz) %>%
  filter(nr != 4) %>%
  print(n = 500)

# UNIFORMIZE PROVINZ AND REGIERUNGSBEZIRK OVER CLEAN NAMES
kreis_names <- kreis_names %>%
  select(data_kreis_clean = kreis_clean, data_kreis_orig = kreis,
        data_provinz_orig = provinz, data_regierungsbezirk_orig = regierungsbezirk) %>%
  group_by(data_kreis_clean) %>%
  mutate(id = row_number()) %>%
  mutate(data_regierungsbezirk = ifelse(id == 1, data_regierungsbezirk_orig, NA),
        data_provinz = ifelse(id == 1, data_provinz_orig, NA)) %>%
  fill(c(data_regierungsbezirk, data_provinz), .direction = "downup") %>%
  ungroup() %>%
  distinct(data_kreis_clean, data_provinz, data_regierungsbezirk,
          data_provinz_orig, data_regierungsbezirk_orig, data_kreis_orig)


# DEFINE STADT & LAND
kreis_names_stadt <- kreis_names %>%
  distinct(data_kreis_clean,  data_regierungsbezirk) %>%
  mutate(data_kreis_clean_stadt = trimws(gsub("\\bstadt\\b", "", data_kreis_clean))) %>%
  group_by(data_kreis_clean_stadt) %>%
  mutate(nr = n()) %>%
  mutate(stadt_land = ifelse(grepl("\\bstadt\\b",data_kreis_clean), "stadt", NA_character_))
%>%
  fill(stadt_land, .direction = "downup") %>%
  ungroup()

# !!! All remaining duplicates are either Stadt or Land
```

```
kreis_names_stadt %>%
  filter(nr > 1) %>%
  print(n = 500)

kreis_names_stadt <- kreis_names_stadt %>%
  filter(nr > 1) %>%
  mutate(data_kreis_clean_stadt_land = ifelse(grepl("\\bstadt\\b",data_kreis_clean) & nr > 1,
data_kreis_clean,
                                        paste0(data_kreis_clean, " land"))) %>%
  select(data_kreis_clean, data_kreis_clean_stadt_land, data_regierungsbezirk)
kreis_names_stadt

# Add back to kreis_names
kreis_names <- kreis_names %>%
  left_join(kreis_names_stadt) %>%
  mutate(data_kreis_clean = ifelse(is.na(data_kreis_clean_stadt_land),
                                   data_kreis_clean, data_kreis_clean_stadt_land)) %>%
  select(-data_kreis_clean_stadt_land) %>%
  rename(provinz = data_provinz_orig, regierungsbezirk = data_regierungsbezirk_orig, kreis
= data_kreis_orig)

kreis_names

# LOAD SPECIALLY PREPARED SHAPEFILE
#===================================
load("1939_1940_1941_1943/
shape_merged_germany_1940_austria_1910_luxembourg_1867_2015.Rda")

# Deduplicate slightly misspelled using jaro-winkler
bla = expand.grid(kreis_names$data_kreis_clean, kreis_names$data_kreis_clean) %>%
  as_tibble() %>%
  set_names(c("kreis_ocr", "kreis")) %>%
  filter(kreis != kreis_ocr) %>%
  mutate(string_dist_jw = stringdist::stringdist(kreis, kreis_ocr, method = "jw"),
         string_dist_lv = stringdist::stringdist(kreis, kreis_ocr, method = "lv")) %>%
  arrange(string_dist_jw)

bla %>% print(n = 100)

look_up_in_shape_and_osm(NULL, „schen")
```

```
#==============================================================
# BUILD CROSS-SECTION OF HARVEST DATA IN NAZI REICH 1939
#==============================================================
rm(list = ls())

library(tidyverse)
library(readODS)
library(janitor)
library(cli)
library(sf)
library(fuzzyjoin)

# Read hand collected Kreis names
kreis_names <- c(
  "1939_1940_1941_1943/R 3102_10967/kreisnamen_kartoffeln.ods",
  "1939_1940_1941_1943/R 3102_10967/kreisnamen_gerste_hafer.ods",
  "1939_1940_1941_1943/R 3102_10967/kreisnamen_mais.ods",
  "1939_1940_1941_1943/R 3102_10967/kreisnamen_roggen_weizen.ods",
  "1939_1940_1941_1943/R 3102_10967/kreisnamen_zuckerrüben.ods"
)

kartoffeln_kreise <- read_ods(kreis_names[1]) %>% rename(Seite = `...5`)
gerste_kreise <- read_ods(kreis_names[2])  %>% rename(Seite = `...5`)
mais_kreise <- read_ods(kreis_names[3])  %>% rename(Seite = `...5`)
roggen_kreise <- read_ods(kreis_names[4])  %>% rename(Seite = `...5`)
rueben_kreise <- read_ods(kreis_names[5])  %>% rename(Seite = `...5`)

# List all files extracted from scans
files <- list.files("1939_1940_1941_1943/R 3102_10967/cropped/output/", pattern = "csv",
full.names = T)

# Find all files with many low confidence numbers
# files_conf <- files[grepl("confidence", files)]
#
# data_conf <- map(files_conf, \(x) read_csv(x) %>%
#             clean_names() %>%
#             mutate(file_name = str_extract(x, "R_.*\\.csv")) %>%
#             mutate_all(\(x) ifelse(x < 0.01, NA, x)) %>%
#             # Filter if any column is below threshold
#             filter(if_any(where(is.numeric), ~ . < 60)))
# low_conf <- map(data_conf, \(x) dim(x)[1]) %>% unlist()
# data_conf[low_conf > 10]
# -> This only shows columns with many hyphens

# Drop all names with confidence
files <- files[!grepl("confidence", files)]
files

# Read files
# Map is a function to efficiently loop over an argument
```

```
# It loops over files, where every item of files is defined as x
# We first load the csv file and we then clean the variable names
data <- map(files, \(x) read_csv(x, col_types = cols(.default = col_character())) %>%
            clean_names() %>%
            mutate(file_name = str_extract(x, "R_.*\\.csv")))

# Add page count
data <- map(1:length(data), \(x) data[[x]] %>%
            mutate(page_nr = x) %>%
            mutate_all(as.character))

# Check dimensions
dims <- data.frame(ncols = map(data, \(x) dim(x)[2]) %>% unlist()) %>%
  mutate(file_name = str_extract(files, "R_.*\\.csv"),
         row_nr = row_number())
dims

# Cleaning
data <- map(data, \(x) x %>%
      mutate_all(trimws))

map(data, \(x) x %>% distinct(file_name))

# MATCH KREIS NAMES WITH DATA ON PAGE NUMBER
roggen <- data[1:31] %>% bind_rows()
gerste <- data[32:62] %>% bind_rows()
mais <- data[63:93] %>% bind_rows()
kartoffeln <- data[94:124] %>% bind_rows()
zuckerrueben <- data[125:155] %>% bind_rows()

# Loop over all pages
glue_data_to_kreis_names = function(df, df_kreise, page_bind_anyways = NULL) {

  pages <- unique(df$page_nr) # Number of pages

  kreis_data <- map(pages, \(page) {
    # Get Kreisnamen per page
    kreise_pg <- df_kreise %>% filter(Seite == page)
    # Get Data per page
    data_pg <- df %>% filter(page_nr == page)
    # Page
    file_name = data_pg$file_name[1]

    # If number of rows match, bind columns
    if (dim(kreise_pg)[1] == dim(data_pg)[1]) {
      cli_alert_success("Number of Kreise and data rows match for page {page} with name
{file_name}")
      df <- bind_cols(kreise_pg, data_pg)
    }
    # If number of rows do not match, return NULL
```

```
    if (dim(kreise_pg)[1] != dim(data_pg)[1]) {
      cli_alert_danger("Number of Kreise and data rows do not match for page {page} with
name {file_name}")
      cli_text(" -> # Kreise {dim(kreise_pg)[1]} vs. # Data {dim(data_pg)[1]}")
      df <- NULL

      if(page %in% page_bind_anyways) {
        cli_alert_warning("Binding data anyways filling NAs in bottom")
        kreise_pg <- kreise_pg %>% mutate(id = row_number())
        data_pg <- data_pg %>% mutate(id = row_number())
        df <- full_join(kreise_pg, data_pg, by = "id") %>% select(-id)
      }

    }
    return(df)
  })
  return(kreis_data)
}

# ROGGEN
roggen <- glue_data_to_kreis_names(roggen, roggen_kreise)

roggen <- roggen %>%
  bind_rows() %>%
  select(-page_nr) %>%
  # Add names
  set_names(c("provinz", "regierungsbezirk", "typ", "kreis", "page",
              "winter_rye_ha", "winter_rye_dz_ha", "winter_rye_dz",
              "summer_rye_ha", "summer_rye_dz_ha", "summer_rye_dz",
              "winter_wheat_ha", "winter_wheat_dz_ha", "winter_wheat_dz",
              "summer_wheat_ha", "summer_wheat_dz_ha", "summer_wheat_dz",
              "file_name"))


# GERSTE
gerste <- gerste %>%
  mutate(page_nr = as.numeric(page_nr) - 31)

gerste <- glue_data_to_kreis_names(gerste, gerste_kreise)

gerste <- gerste %>%
  bind_rows() %>%
  select(-page_nr) %>%
  # Add names
  set_names(c("provinz", "regierungsbezirk", "typ", "kreis", "page",
              "emmer_ha", "emmer_dz_ha", "emmer_dz",
              "winter_barley_ha", "winter_barley_dz_ha", "winter_barley_dz",
              "summer_barley_ha", "summer_barley_dz_ha", "summer_barley_dz",
              "oats_ha", "oats_dz_ha", "oats_dz",
              "file_name"))
```

```
# MENGGETREIDE & MAIS
mais <- mais %>%
  mutate(page_nr = as.numeric(page_nr) - 62)

mais <- glue_data_to_kreis_names(mais, mais_kreise, page_bind_anyways = 13)

mais <- mais %>% bind_rows() %>%
  select(-page_nr) %>%
  # Add names
  set_names(c("provinz", "regierungsbezirk", "typ", "kreis", "page",
              "winter_mixed_grains_ha", "winter_mixed_grains_dz_ha",
"winter_mixed_grains_dz",
              "summer_mixed_grains_ha", "summer_mixed_grains_dz_ha",
"summer_mixed_grains_dz",
              "grain_maize_ha", "grain_maize_dz_ha", "grain_maize_dz",
              "buckwheat_ha", "buckwheat_dz_ha", "buckwheat_dz",
              "file_name"))

# KARTOFFELN
# Match em
kartoffeln <- kartoffeln %>%
  mutate(page_nr = as.numeric(page_nr) - 93)
kartoffeln

kartoffeln <- glue_data_to_kreis_names(kartoffeln, kartoffeln_kreise)

# Stack all pages on top of each other
kartoffeln <- kartoffeln %>%
  bind_rows() %>%
  select(-page_nr) %>% #Seitenzahl nur zum zsmführen relevant; dann gelöscht
  # Add names
  set_names(c("provinz", "regierungsbezirk", "typ", "kreis", "page",
              "other_grains_or_legumes_ha",
              "potatoes_late_ha", "potatoes_late_dz_ha", "potatoes_late_dz",
              "potatoes_common_early_ha", "potatoes_chitted_early_ha", "potatoes_early_ha",
              "potatoes_early_dz_ha", "potatoes_early_dz",
              "file_name"))

# RUEBEN
zuckerrueben
zuckerrueben <- zuckerrueben %>%
  mutate(page_nr = as.numeric(page_nr) - 124)

zuckerrueben <- glue_data_to_kreis_names(zuckerrueben, rueben_kreise)
zuckerrueben

zuckerrueben <- zuckerrueben %>%
  bind_rows() %>%
  select(-page_nr) %>% #Seitenzahl nur zum zsmführen relevant; dann gelöscht
  # Add names
```

```
  set_names(c("provinz", "regierungsbezirk", "typ", "kreis", "page",
            "sugar_beets_ha", "sugar_beets_dz_ha", "sugar_beets_dz",
"sugar_beets_seeds_ha",
            "feed_beets_ha", "feed_beets_dz_ha", "feed_beets_dz", "feed_beets_seeds_ha",
            "rutabaga_ha", "rutabaga_dz_ha", "rutabaga_dz", "rutabaga_seeds_ha",
            "file_name"))

harvest_1943 <- list(kartoffeln, roggen, gerste, mais, zuckerrueben)

save(harvest_1943, file = "1939_1940_1941_1943/R 3102_10967/harvest_1943_raw.rda")
```